

פרויקט גמר · ניתוח מאגרי מידע

בעקבות הפנינים הנסתרות: זיהוי Hidden Gems בשוק ה-Airbnb ברומא

טיוטת דוח סופי להגשה, בנוי לפי מבנה ההגשה של הקורס (כותרת, צוות, דומיין, נתונים, לכל בעיה - פתרון והערכה, עבודה עתידית, מסקנה). לפני ההגשה: להמיר ל-PDF, לוודא עמידה במגבלת 6 העמודים (לא כולל תמונות), ולשנות את שם הקובץ ל-`writeup_group##.pdf`.

צוות הפרויקט

- [שם מלא] — [אימייל] — [ת.ז. / מספר סטודנט]
- (להוסיף חברות/חברי צוות נוספים בהתאם)

פלטפורמות השכרה קצרת-טווח, כגון Airbnb, מציעות אלפי נכסים המתחרים על חשיפת המשתמשים, בעוד שבפועל רק חלק קטן מהם זוכה לבולטות גבוהה בתוצאות החיפוש. כתוצאה מכך, נכסים איכותיים עשויים להישאר פחות מוכרים. בפרויקט זה התמקדנו בשוק ה-Airbnb ברומא, איטליה, והגדרנו נכס כ-**"Hidden Gem"** כאשר הוא עומד בשלושה תנאים מרכזיים: הוא מתומחר באופן אטרקטיבי ביחס לנכסים דומים, זוכה לביקורות חיוביות, ובו בזמן אינו מוכר במיוחד. מטרתנו הייתה לבחון האם ניתן לזהות נכסים כאלה באופן אוטומטי באמצעות נתוני נכסים וביקורות ציבוריים, להבין אילו מאפיינים מייחדים אותם משאר השוק, ולבדוק האם הם מתחלקים לתת-קבוצות בעלות מאפיינים משותפים.

נתונים

שני קבצי מקור גולמיים (רומא, בסגנון ייצוא Airbnb Inside):

קובץ	מספר שורות	גודל	תיאור
data/listings.csv	37,583	7.0MB	שורה לכל נכס: מיקום, מחיר, סוג חדר, פרטי מארח, כמות ביקורות, זמינות
data/reviews.csv	2,477,671	801MB	שורה לכל ביקורת: מזהה נכס, תאריך, שם המבקר/ת, טקסט חופשי

ניקוי ובעיית שאותרו:

לאחר טעינת הנתונים ביצענו שלב מקיף של ניקוי ועיבוד מקדים עבור קובצי הנכסים והביקורות. בקובץ הנכסים (`clean_listings.py` ← `listings_cleaned_2025.csv`) הוסרו רשומות כפולות, שדה המחיר הומר לערך מספרי, והושארו רק נכסים בעלי מחיר תקין ולפחות ביקורת אחת משנת 2025. בקובץ הביקורות (`clean_reviews.py` ← `reviews_cleaned_2025.csv`) סוננו ביקורות משנת 2025 בלבד, ובוצע ניקוי של טקסט ההודעות (כגון הסרת תגיות HTML, קישורים ורווחים מיותרים).

בשל מספרן הרב של הביקורות ובמטרה להימנע מהטיות ושגיאות הנובעות מתרגום אוטומטי, בחרנו להתמקד בביקורות שנכתבו באנגלית בלבד. במהלך הפרויקט התברר כי שיטת סינון השפה הראשונית לא הייתה מדויקת מספיק, וכי חלק מהביקורות שסווגו כאנגליות נכתבו למעשה בשפות אחרות (כ-42% מהן, לפי בדיקה מדגמית). לכן, לצורך ניתוח הטקסט, ביצענו סינון מדויק יותר באמצעות הספרייה `langdetect` והשארנו רק ביקורות שזוהו כאנגלית.

לבסוף, הדאטהסט לא כלל מספר מאפיינים הקיימים בדרך כלל בנתוני Airbnb Inside, כגון `accommodates`, `amenities_count`, `bedrooms` ו-`bathrooms`. היעדר משתנים אלו הגביל את שלב ה-Clustering, שהתבסס בעיקר על מאפיינים גיאוגרפיים במקום על מאפייני הנכס עצמו.

בעיה 1 - חיזוי "מחיר הוגן" לנכס

תיאור הבעיה וההשערה:

השלב הראשון בזיהוי נכסי ה-**Hidden Gems** היה להעריך מהו המחיר הצפוי של כל נכס בהתאם למאפייניו. הנחנו כי מחיר של נכס מושפע ממאפיינים נצפים, ובהם מיקומו, סוג הנכס, זמינותו, מספר הביקורות והדירוג שקיבל. בהתאם לכך, פער בין המחיר בפועל לבין המחיר שחזה המודל עשוי להעיד על כך שהנכס מתומחר בחסר או ביתר ביחס לנכסים בעלי מאפיינים דומים. מדד זה שימש בהמשך כאחד הקריטריונים לזיהוי נכסי **Hidden Gem**.

השיטה:

לצורך חיזוי המחיר אימנו מודל עץ החלטה מסוג `DecisionTreeRegressor`. משתנה המטרה היה הלוגריתם של מחיר הנכס, שנבחר כדי לצמצם את השפעתם של מחירים חריגים ולמתן את ההתפלגות הימנית של המחירים.

המודל התבסס על מאפיינים הנוגעים לפעילות הנכס והמארח, ובהם מספר הלילות המינימלי להזמנה, מספר הביקורות, קצב קבלת הביקורות, מספר הנכסים של המארח, זמינות שנתית ודירוג הנכס. בנוסף, כללנו את סוג החדר ואת אזור הנכס באמצעות קידוד קטגוריאלי. (גם `accommodates` נדרש כ-`feature` אך אינו קיים בנתונים ומולא בקבוע 0, ולכן לא תרם שום מידע בפועל — מצוין כאן לשקיפות.)

הנתונים חולקו באופן אקראי לקבוצת אימון שכללה 80% מהנכסים ולקבוצת בדיקה שכללה 20%. לאחר אימון המודל חישבנו עבור כל נכס את המחיר החזוי, ואת הפער בין המחיר בפועל למחיר החזוי. פער שלילי הצביע על נכס שמחירו נמוך מהמחיר

שהמודל צפה עבורו.

קריטריון הערכה:

את ביצועי המודל הערכנו על קבוצת הבדיקה בלבד, כדי לבחון את יכולתו לחזות מחירים של נכסים שלא נכללו באימון. השתמשנו במדדי RMSE ו-MAPE, המודדים בהתאמה את גודל טעות החיזוי ואת שיעור הסטייה היחסי בין המחיר בפועל למחיר החזוי.

בנוסף, השווינו בין הביצועים על קבוצת הבדיקה לבין הביצועים על כלל הנתונים. השוואה זו נועדה לבדוק האם המודל התאים את עצמו יותר על המידה לנתוני האימון.

Setup:

לצורך הערכת ביצועי המודל השתמשנו בקבוצת הבדיקה, שכללה 20% מהנכסים ולא שימשה בתהליך האימון. טעויות החיזוי חושבו הן בסולם הלוגריתמי שבו אומן המודל, והן לאחר המרת התחזיות חזרה למחירים ביורו, כדי לאפשר פרשנות מעשית של התוצאות.

תוצאות:

מדד	test set (הוגן)	כל הדאטה כולל שורות אימון (מטעה)
RMSE (log price)	0.639 (טעות מכפילה של כ-פי 1.9)	0.286 (כ-פי 1.33)
RMSE (מחיר, יורו)	—	154.39
MAE (מחיר, יורו)	—	23.87
MAPE	—	11.79%
חציון APE	—	0.00%

ניזולאליזציה:

מחיר בפועל מול מחיר חזוי (סקאלת log-log) על ה-test set, כאשר 63 ה-Hidden Gems הסופיים מודגשים.

קשיים וממצא מתודולוגי מרכזי:

במהלך הערכת המודל התברר כי עץ ההחלטה סבל מהתאמת יתר משמעותית. כאשר הביצועים חושבו על כלל הנתונים, שכללו גם את הרשומות ששימשו לאימון, התקבלה טעות נמוכה באופן מלאכותי. לעומת זאת, ההערכה על קבוצת הבדיקה הראתה כי יכולת ההכללה של המודל מוגבלת וכי טעות החיזוי בפועל גבוהה יותר.

ממצא זה מדגיש את החשיבות של הערכת מודלים על נתונים שלא שימשו בתהליך האימון. במקרה שלנו, ההערכה על כלל הנתונים לא שיקפה את איכות החיזוי האמיתית, משום שהעץ למד חלק גדול מנתוני האימון באופן כמעט מדויק.

לתופעה זו הייתה גם השלכה על שלב זיהוי ה-Hidden Gems. עבור נכסים שנכללו באימון, המחיר החזוי היה לרוב קרוב מאוד למחיר בפועל, ולכן הפער ביניהם היה קטן מכדי לעמוד בקריטריון של מחיר הנמוך ב-15% מהמחיר החזוי. בהתאם לכך, כל 63 הנכסים שסווגו כ-Hidden Gems נמצאו בקבוצת הבדיקה. משמעות הדבר היא שהסיווג שלהם התבסס על תחזיות עבור נכסים שהמודל לא ראה במהלך האימון, ולא על התאמה חוזרת לנתוני האימון.

בעיה 2 - זיהוי נכסי "Hidden Gem"

תיאור הבעיה וההשערה:

מטרת שלב זה הייתה לזהות נכסים מהווים Hidden Gems – נכסים איכותיים שאינם זוכים לחשיפה רבה, אך מציעים תמורה גבוהה ביחס למחירים. הנחנו כי ניתן לזהות נכסים כאלה באמצעות שילוב של שלושה מאפיינים: פופולריות נמוכה יחסית, שביעות רצון גבוהה של האורחים ומחיר הנמוך מהמחיר הצפוי עבור נכסים בעלי מאפיינים דומים.

השיטה:

תהליך הזיהוי התבסס על שלושה קריטריונים משלימים. תחילה נותחו כל הביקורות באמצעות מודל הסנטימנט VADER, ומתוכן חושב לכל נכס שיעור הביקורות החיוביות. לאחר מכן סווגו נכסים כבעלי חשיפה נמוכה כאשר מספר הביקורות שקיבלו בשנת 2025 היה נמוך מהחציון בכלל המדגם. לבסוף, שילבנו מידע זה עם תוצאות מודל חיזוי המחיר (בעיה 1), כך שנכס הוגדר כ-Hidden Gem רק אם עמד בשלושת התנאים הבאים:

1. מספר ביקורות נמוך מהחציון.

2. יותר מ-75% מהביקורות שלו סווגו כחיוביות.

3. מחירו בפועל נמוך בלפחות 15% מהמחיר שחזה מודל חיזוי המחיר.

הערכה:

מאחר שלא קיים תיוג אמת (Ground Truth) לנכסי Hidden Gem, לא ניתן היה להעריך את ביצועי האלגוריתם באמצעות מדדי דיוק מקובלים. לכן בחרנו בשתי שיטות הערכה. הראשונה הייתה בחינת כוח ההבחנה של כל אחד משלבי הסינון, כלומר כיצד כל קריטריון מצמצם את קבוצת המועמדים. השנייה הייתה הערכה איכותנית של הנכסים שנבחרו, באמצעות בחינת המחיר, דירוגי הביקורות ותוכן הביקורות עצמם, כפי שמוצג גם בניתוח ענני המילים בבעיה 4.

Setup:

שלושת קבצי המקור אוחדו (inner join) לפי `listing_id`, כך שאוכלוסיית ההערכה מוגבלת ל-7,884 הנכסים שמופיעים בשלושתם (נכסים עם מחיר, ביקורות, וגם תחזית מחיר).

תוצאות:

לאחר איחוד כלל מקורות המידע התקבלו 7,884 נכסים שניתן היה להעריך. מתוכם 4,086 נכסים (51.8%) סווגו כבעלי חשיפה נמוכה. לאחר הוספת תנאי הסנטימנט נותרו 1,150 נכסים (14.6%), ולבסוף רק 63 נכסים (0.8%) עמדו בכל שלושת הקריטריונים והוגדרו כ-Hidden Gems.

ויזואליזציה:

`docs/assets/hidden_gem_funnel.png` (משפך שלוש שלבי הסינון), וכן הנקודות המודגשות בגרף הפיזור של בעיה 1 (כל 63 הנכסים נמצאים משמעותית מעל קו ה- $y=x$, כלומר המחיר החזוי גבוה בבירור מהמחיר בפועל).

קשיים:

האתגר המרכזי בשלב זה היה היעדר תיוג אמת של נכסי Hidden Gem. לכן לא ניתן היה לחשב מדדי הערכה מקובלים כגון Recall ו-Precision. הספים שנבחרו — מספר ביקורות הנמוך מהחציון, שיעור חיוביות של מעל 75% ומחיר הנמוך בלפחות 15% מהמחיר החזוי — מבוססים על היגיון מחקרי, אך לא כוילו באמצעות מדגם מתווג.

בנוסף, קריטריון המחיר תלוי באיכות התחזיות של המודל מהשלב הקודם, ולכן הוא מושפע גם ממגבלותיו. עם זאת, כל הנכסים שסווגו כ-Hidden Gems נמצאו בקבוצת הבדיקה, ולכן התחזית עבורם לא התבססה על נתונים שהמודל כבר ראה במהלך האימון. עובדה זו מחזקת את מהימנות הסיווג, אך אינה מבטלת את מגבלת התאמת היתר של מודל המחיר.

בעיה 3 – אפיון תתי-קבוצות של נכסי Hidden Gem

תיאור הבעיה וההשערה:

הנחנו כי נכסי Hidden Gems אינם מהווים קבוצה אחידה, אלא עשויים להתחלק לתתי-קבוצות בעלות מאפיינים משותפים. זיהוי קבוצות כאלה יכול לסייע בהבנת סוגים שונים של Hidden Gems, למשל לפי אזור גיאוגרפי או מאפייני הנכס.

השיטה:

לצורך זיהוי תתי-קבוצות השתמשנו באלגוריתם K-means על 63 הנכסים שסווגו כ-Hidden Gems בשלב הקודם. במקור תכננו לבצע את החלוקה על בסיס מיקום הנכס, מספר האורחים שהוא יכול לארח ומספר השירותים שהוא מציע. עם זאת, מאחר שהמשתנים הנוגעים לקיבולת ולשירותים לא היו זמינים בדאטהסט, הניתוח התבסס בפועל על קווי הרוחב והאורך בלבד.

לפני הפעלת האלגוריתם בוצעה סטנדרטיזציה של משתני המיקום, מאחר ש-K-means מבוסס על מרחקים ורגיש להבדלים בסקאלה. לא נמצאו ערכים חסרים במשתני המיקום, ולכן כל 63 הנכסים נכללו בניתוח.

בחירת מספר הקבוצות:

השווינו בין פתרון הכולל שלוש קבוצות לבין פתרון הכולל ארבע קבוצות. ההשוואה התבססה על ציון Silhouette, וכן על בחינה איכותנית של גודל הקבוצות, מיקומן וההתאמה שלהן לאזורי העיר.

הפתרון של שלוש קבוצות השיג ציון Silhouette גבוה יותר, 0.81 לעומת 0.63 בפתרון של ארבע קבוצות. עם זאת, הוא יצר חלוקה לא מאוזנת: 60 מתוך 63 הנכסים רוכזו בקבוצה אחת, בעוד שלוש הרשומות הנותרות חולקו לשתי קבוצות זעירות. לכן, אף שהציון הכמותי היה גבוה יותר, החלוקה לא סיפקה אפיון משמעותי של תתי-אזורים.

לעומת זאת, הפתרון של ארבע קבוצות יצר חלוקה שימושית יותר מבחינה פרשנית. בפרט, הוא זיהה תתי-קבוצה של שבעה נכסים באזור דרום-מזרח רומא, הכולל אזורים כגון ג'ובאני, צ'ינצ'יטה ואפיה אנטיקה. מסיבה זו בחרנו בפתרון של ארבע קבוצות, אף שציון ה-Silhouette שלו היה נמוך יותר.

תוצאות:

ה-Clustering הצביע על כך שרוב נכסי ה-Hidden Gems מרוכזים במרכז רומא, בעוד שמספר קטן יותר ממוקם באזורים מרוחקים יותר. הפתרון שנבחר אפשר להבחין בין הקבוצה המרכזית לבין תת-קבוצה גיאוגרפית נפרדת בדרום-מזרח העיר.

Cluster	שם	n	מחיר ממוצע	הנחה ממוצעת	חיוביות ממוצעת	ביקורות ממוצע	סוג נכס דומיננטי
0	פנינות המרכז ההיסטורי המבוססות	53	€195.8	42.1%	93.9%	101.6	69.8% דירה שלמה
2	חדרים פרטיים במחיר מציאה, דרום-מזרח רומא	7	€77.3	49.4%	95.6%	74.3	71.4% חדר פרטי
3	פנינות פרבריות/חוף שקטות (אוסטיה/פורטואנזה)	2	€115.5	20.1%	100%	11.5	100% דירה שלמה
1	חריג צפוני בודד (קאסיה/פלמיניה)	1	€88.0	45.0%	100%	57.0	100% דירה שלמה

ויזואליזציה:

החלוקה הוצגה על גבי מפת רומא, שבה כל נכס סומן לפי הקבוצה שאליו שויך, לצד מרכזי הקבוצות. הצגה זו אפשרה לפרש את תוצאות האלגוריתם בהקשר גיאוגרפי ממשי ולא רק באמצעות המרחקים המספריים בין הנקודות.

קשיים ומגבלות:

המגבלה המרכזית של הניתוח הייתה היעדרם של משתנים המתארים את מאפייני הנכס, כגון מספר האורחים האפשרי ומספר השירותים. לכן, תוצאות ה-Clustering משקפות חלוקה לפי מיקום בלבד, ולא לפי סוג הנכס או חוויית האירוח שהוא מציע.

בנוסף, מספר הנכסים היה קטן והתפלגותם הגיאוגרפית לא הייתה אחידה. רובם היו מרוכזים במרכז העיר, בעוד שבחלק מהקבוצות נכללו נכס אחד או שניים בלבד. קבוצות כה קטנות עשויות לשקף נקודות חריגות יותר מאשר תת-קבוצה יציבה, ולכן יש לפרש אותן בזהירות.

בעיה 4 – אילו מאפיינים עולים משפת הביקורות על Hidden Gems?

תיאור הבעיה וההשערה:

לאחר זיהוי נכסי ה-Hidden Gems ביקשנו לבחון האם האופן שבו אורחים מתארים אותם שונה מהאופן שבו מתוארים יתר הנכסים. הנחנו כי ניתוח השפה בביקורות עשוי לחשוף מאפיינים איכותניים של חוויית האירוח, שאינם באים לידי ביטוי בקריטריונים הכמותיים ששימשו לזיהוי הנכסים.

השיטה:

השווינו בין טקסט הביקורות של 63 נכסי ה-Hidden Gems לבין הביקורות על יתר הנכסים. מאחר שהניתוח התבסס על מבנים לשוניים באנגלית, בוצע תחילה סינון שפה באמצעות langdetect, ולאחריו נכללו 300 ביקורות באנגלית על נכסי Hidden Gem ו-339,336 ביקורות באנגלית בקבוצת ההשוואה.

הטקסטים עברו עיבוד מקדים שכלל פירוק למילים, תיוג חלקי דיבר והסרת מילות עצירה. בנוסף הוסרו מילים נפוצות הקשורות ישירות לתחום, כגון Rome, apartment ו-Airbnb, מאחר שהן הופיעו בתדירות גבוהה אך לא תרמו להבחנה בין הקבוצות.

לצורך הניתוח נשמרו צירופים סמוכים של תואר ושם עצם, כגון great location ו-quiet neighborhood. המילים הומרו לצורת הבסיס שלהן באמצעות Lemmatization, כדי לאחד הטיות שונות של אותה מילה תוך שמירה על צורות קריאות. תדירות הצירופים חושבה בנפרד בכל קבוצה, ולאחר מכן הוצגה באמצעות ענני מילים שנבנו באותן הגדרות עיצוב.

הערכה:

מאחר שמדובר בניתוח איכותני ללא תיוג אמת, ההערכה התבססה על פרשנות סמנטית של הצירופים הבולטים בכל קבוצה. בחנו האם ענני המילים מציגים נושאים ברורים ועקביים, והאם הם מוסיפים הסבר איכותני להבדלים שנמצאו בשלבים הכמותיים של הפרויקט.

חשוב להדגיש כי ענני המילים אינם מוכיחים הבדל סטטיסטי בין הקבוצות, אלא משמשים כלי חקרני להצגת דפוסים אפשריים בשפה.

תוצאות:

צירופים הקשורים למיקום היו בולטים בשתי הקבוצות, דבר המצביע על חשיבותו הכללית של המיקום בחוויית האירוח. עם זאת, הם הופיעו בשיעור גבוה יותר בביקורות על נכסי Hidden Gem: כ-7% מהביקורות בקבוצה זו כללו צירוף הקשור למיקום, לעומת כ-5.1% בקבוצת ההשוואה.

מעבר לכך, בביקורות על נכסי Hidden Gem בלטו צירופים המתייחסים ליחס אישי מצד המארח, לתקשורת ולפרטים קטנים בחוויית האירוח, כגון *thoughtful touch*, *good communication* ו-*detailed instruction*. הופיעו גם התייחסויות לפרטים פיזיים מסוימים בנכס, כמו *washing machine* ו-*ear plug*.

לעומת זאת, בביקורות על יתר הנכסים בלטו יותר צירופים הקשורים לנוחות לוגיסטית, נגישות ותשתיות סביבתיות, כגון *easy access*, *public transportation*, *metro station* ו-*quiet neighborhood*. תוצאות אלו מציעות כי נכסי Hidden Gems עשויים לבלוט פחות בזכות שירותים סטנדרטיים או תשתיות, ויותר בזכות חוויה אישית ותשומת לב לפרטים.

ויזואליזציה:

האיור הבא מציג את ענן המילים של נכסי Hidden Gems, ואחריו את ענן המילים של יתר הנכסים. שני העננים נבנו באותן הגדרות, כך שההבדלים החזותיים משקפים את שכיחות הצירופים בכל קבוצה ולא הבדלים באופן ההצגה.

10 הצירופים המובילים — Hidden Gems:

#	צירוף	מספר הופעות
1	great location	21
2	great restaurant	8
3	main attraction	7
4	public transport	5
5	perfect location	5
6	good restaurant	5
7	amazing location	5
8	next door	4
9	major attraction	4
10	last minute	4

10 הצירופים המובילים — שאר הנכסים:

#	צירוף	מספר הופעות
1	great location	17,225
2	great restaurant	8,016
3	good location	7,249
4	short walk	6,676
5	perfect location	6,426
6	public transport	6,381
7	easy access	5,082
8	main attraction	4,837
9	comfortable bed	4,393
10	great time	4,216

קשיים ומגבלות:

קבוצת Hidden Gems כללה 300 ביקורות באנגלית בלבד, לעומת יותר מ-339 אלף ביקורות בקבוצת ההשוואה. חוסר האיזון בין הקבוצות מגדיל את הרגישות של ענן Hidden Gems לצירופים נדירים ולמקרים בודדים. לכן יש לפרש בעיקר

צירופים שחזרו מספר פעמים והציגו דפוס עקבי, ולא להסיק מסקנות מצירופים בודדים.

בנוסף, ענני מילים מציגים שכיחות אך אינם מביאים בחשבון באופן מלא הקשר, שלילה או מובהקות סטטיסטית. לפיכך, הניתוח משמש השלמה איכותנית לתוצאות הכמותיות ולא תחליף לבדיקת הבדלים סטטיסטית. מתודולוגיה מלאה והרחבה על המגבלות מתועדות בנפרד בקובץ `wordcloud_analysis.md`.

עבודה עתידית

- להשיג ייצוא מלא יותר של נכסים (הכולל `bathrooms`, `bedrooms`, `amenities_count`, `accommodates`) ולהריץ מחדש את ה-clustering של בעיה 3 לפי מאפייני הנכס בפועל, ולא רק גיאוגרפיה — כדי לענות במלואה על שאלת "סוגי ה-Hidden Gems המקורית".
- להגביל את עץ ההחלטה מבעיה 1 (`min_samples_leaf`, `max_depth`) או לנסות מודל אנסמבל (Random Forest / Gradient Boosting) כדי לצמצם overfitting ולקבל סימן פער-מחיר מהימן יותר.
- להעביר את סינון השפה שהוספנו לצעד המקדים עצמו (`clean_reviews.py`), כך שכל הקבצים בהמשך ייהנו מסינון אנגלית מדויק, לא רק שלב ענני המילים.
- לוודא את הגדרת ה-Hidden Gem מול איתות חיצוני אם יימצא (למשל בדיקה ידנית של מדגם מ-63 הנכסים, או השוואה מול סטטוס Superhost / קצב תגובה אם שדות כאלה יהיו זמינים).
- להרחיב את ניתוח ענני המילים לכל cluster בנפרד (שילוב בעיה 3 עם בעיה 4), ולבדוק האם הפיצול "מיקום מול יחס אישי" נשמר גם בתוך כל אזור גיאוגרפי.

מסקנה

התחלנו מנתוני נכסים וטקסט ביקורות גולמיים, ובנינו פייפליין מקצה-לקצה ש-(1) לומד קו בסיס לחיזוי מחיר, (2) משלב נפח ביקורות, סנטימנט, ופער מחיר-מול-חיזוי להגדרה עקבית של "3", Hidden Gem" מראה שה-63 הנכסים שהתקבלו מתחלקים לתתי-סוגים גיאוגרפיים נבדלים, ו-(4) משתמש בכריית טקסט כדי להראות למה בעצם מעריכים אותם — חוויה אישית ומארכת יותר — לעומת הפנייה המבוססת-מיקום-ולוגיסטיקה של הנכסים הפופולריים. במהלך הדרך גילינו ותיקנו שתי בעיות איכות נתונים אמיתיות (תו מירכאות ששיבש קובצי CSV, וסינון שפה אנגלית מקל מדי) וכן מלכודת overfitting חשובה במודל המחיר — שני הממצאים האלה שינו באופן מהותי, ובסופו של דבר חיזקו את מהימנות התוצאות הסופיות.